

Kod Tabanı Soru-Cevap Asistanı

Staj projesi · 20 günlük iş paketi ve gün gün çalışma raporu

Yusuf Güneş · 10 Ağustos – 4 Eylül 2026 · 4 hafta, 20 iş günü

Bir kod tabanını indeksleyip doğal dildeki (Türkçe) sorulara **dosya ve satır referanslı** cevap veren bir araç geliştirildi. Amaç, yeni bir projeye adapte olma süresini kısaltmak: her cevap kaynak gösterdiği için doğruluğu anında kontrol edilebiliyor. Araç komut satırından, yerel web arayüzünden ve Claude Code'un içinden (MCP) kullanılabiliyor.

Ölçülen sonuç: iki Python kod tabanında, hiçbir ayarın görmediği test bölmelerinde — anthropic SDK'sının en zor setinde getirme **%96**, kapsam **%90**; ikinci kod tabanı Saleor'da **%100 / %96**. Aynı zor setin 26 soruluk test bölümünde uçtan uca cevap doğruluğu **%100**, cevabın referans verdiği dosya kapsamı **%91**, uydurma referans **0**.

Ölçüt	Değer
Kod	16 modül, 4.868 satır Python; 239 birim testi (2.973 satır) — ağ ve API anahtarı gerektirmiyor
Ölçüm	2 kod tabanı, 5 soru seti, 238 soru (96 dev / 142 test); 140 kayıtlı koşu
Arayüzler	CLI (index / embed / search / ask / eval / ui / serve), yerel web arayüzü, MCP sunucusu
Belgeler	README (703 satır), DEMO.md + DEMO_KOMUTLAR.txt, devir belgesi, soru seti rehberi, kullanıcı deneyi protokolü, tanıtım sayfası
Sürüm geçmişi	29 commit (10 Ağustos – 2 Eylül), 25 Ağustos'ta ara rapor
Toplam API harcaması	yaklaşık 12–15 ABD doları (embedding, cevap ölçümleri, contextual retrieval denemesi)

Bu belge nasıl derlendi. Günlere dağılım depodaki git geçmişine (29 commit), `runs/` altındaki tarih damgalı 140 koşu kaydına, README, DEMO.md ve 25 Ağustos tarihli ara rapora dayanıyor. Birden çok günün işi tek commit'te toplandığı yerlerde (örneğin 24 Ağustos ve 1 Eylül) işler yapıldıkları güne yazıldı. Depoya yansımayan çalışmalar (okuma, toplantı, deneme-yanılma) ilgili güne eklenebilir.

1. Projenin son hâli

Boru hattı dört katmandan oluşuyor. **Parçalama:** kod sabit uzunlukta bloklara değil, sözdizimi ağacı (AST) üzerinden fonksiyon / metot / sınıf / modül parçalarına bölünüyor; her parça gerçek satır aralığını taşıyor — dosya:satır referansı verebilmenin ön şartı. **Arama:** parçalar `voyage-code-3` ile vektörleştiriliyor (içerik karması önbellesiyle), BM25 ile birlikte RRF üzerinden birleştiriliyor ve üç genişletme eksenleriyle (dosya çeşitliliği, dizin kardeşi, import bağı) ilk sonuçlar zenginleştiriliyor. **Cevaplama:** bulunan parçalar satır numaralı bağlam olarak Claude'a veriliyor; model eksik kalan yerleri `read_file` ve `search_symbol` araçlarıyla kendisi okuyor; cevaptaki her referans programla doğrulanıyor. **Ölçüm:** getirme ve cevap ayrı ayrı, dev/test bölmeleriyle ve güven aralıklarıyla ölçülüyor.

Modüller

Modül	Görev
<code>indexer.py</code>	Python AST sembol çıkarıcı (fonksiyon, metot, sınıf, modül; imza, docstring, dekoratör, satır aralığı)
<code>docs.py</code>	Markdown'ı başlık hiyerarşisine göre parçalar
<code>models.py</code>	Chunk veri modeli, <code>embed_text</code> , <code>content_hash</code> , JSONL okuma/yazma
<code>embeddings.py</code>	Sağlayıcı arayüzü: Voyage (bulut), Ollama (yerel), hash (yer tutucu) + disk önbellesi
<code>search.py</code>	BM25 + vektör araması, RRF birleştirme, genişletme eksenleri, mod çözümü
<code>facets.py</code>	Belirsiz sorguyu dizin ağacına göre öbekleme (isteğe bağlı, ölçüldü)
<code>rerank.py</code>	Voyage rerank-2.5 (ölçüldü, varsayılan kapalı)
<code>contextual.py</code>	LLM ile bağlam cümlesi üretimi (ölçüldü, varsayılan kapalı)
<code>answer.py</code>	Claude + araçlar, yol hapsi, referans doğrulama, prompt önbellesi
<code>evaluation.py</code>	Soru seti, dev/test bölmesi, recall / kapsam / MRR / sembol isabeti, Wilson güven aralığı
<code>mcp_server.py</code>	MCP sunucusu: <code>search_code</code> , <code>read_chunk</code> , <code>index_status</code> (Claude Code entegrasyonu)
<code>projects.py</code>	Proje kaydı, tarama, maliyet tahmini, dil işareti, duman testi, arka plan işleri
<code>ui.py</code> / <code>ui.html</code>	Yerel web arayüzü (bağımlılıksız <code>http.server</code>): proje ekleme, soru, referansa tıklayınca kaynak
<code>cli.py</code>	Komut satırı: <code>index</code> , <code>embed</code> , <code>search</code> , <code>ask</code> , <code>eval</code> , <code>contextualize</code> , <code>ui</code> , <code>serve</code> , <code>stats</code> , <code>grep</code>

Sonuçlar (test bölmeleri, varsayılan yapılandırma)

Set	Kod tabanı	n	recall@8	kapsam	MRR
Kolay (tek konum)	anthropic SDK	40	%92	%92	0.701
Akış (2–4 dosya)	anthropic SDK	30	%93	%87	0.808
Zor	anthropic SDK	26	%96	%90	0.757
Saleor (karışık)	Saleor (Django e-ticaret)	26	%100	%96	0.573
Kendi kodu	codeqa	20	%100	%100	0.794

Cevap ölçümü (zor set, test, 26 soru, claude-haiku-4-5)	Değer
Doğru cevap oranı	%100 (26/26, %95 GA: %87–%100)
Cevabın referans verdiği dosya kapsamı	%91
Uydurma (doğrulanamayan) referans	0 — projenin tamamında bir kez görüldü, doğrulama katmanı yakaladı
Canlı soru süresi / maliyeti	6–13 saniye · 0,6–2,2 sent

Bu sayılar önceki sürümde daha yüksekti (%100 / %93 / 0.847). Araç değişmedi; test bölmeleri 44'ten 142 soruya çıkarıldı ve küçük örneklem iyimserliği ortadan kalktı. Bu, projenin bilinçli olarak korunan bir sonucu: rapor edilen sayı, hiçbir ayarın görmediği bölmeden alınıyor.

2. İş paketi — genel görünüm

Dört hafta, dört iş paketi: **H1 temel katmanlar** (indeksleme, embedding, arama, cevaplama, ölçüm), **H2 ölçüm ve iyileştirme** (büyük repo, dev/test ayrımı, ilk reddedilen fikir), **H3 entegrasyon ve zor sorular** (MCP, akış ve zor setler, genişletme eksenleri, ara rapor), **H4 genelleme ve sunum** (ikinci kod tabanı, web arayüzü, demo provaları, sunum).

Gün	Tarih	Başlık	Ana çıktı
1	10 Ağu Pzt	Kurulum ve indeksleme katmanı	indexer / docs / models, CLI index-grep-stats, 21 test
2	11 Ağu Sal	Embedding katmanı	Voyage / Ollama / hash sağlayıcıları, içerik karması önbellesi
3	12 Ağu Çar	Arama katmanı ve ilk koşullar	BM25 + vektör + RRF; ilk 8 ölçüm koşusu
4	13 Ağu Per	Cevaplama katmanı	Claude + araçlar, yol hapsi, referans doğrulama, prompt önbellesi
5	14 Ağu Cum	Ölçüm düzeneği	evaluation.py, 20 soruluk ilk set, runs/ kayıtları; 108 test
6	17 Ağu Pzt	Reranking, yerel modeller, ilk gerçek hata	rerank.py; bge-m3 / nomic ölçümü; content_hash hatası
7	18 Ağu Sal	Büyük repo soru seti, dev/test ayrımı	anthropic SDK 60 soru (40 dev / 20 test)
8	19 Ağu Çar	Dil farkı bulgusu	Türkçe tokenizer hatası; hibrit aramanın büyük repoda kaybettiği ölçüldü
9	20 Ağu Per	Contextual retrieval uygulaması	contextual.py: önbellekli, paralel, dayanıklı üretim
10	21 Ağu Cum	Contextual retrieval ölçümü ve karar	+2 puan, \$5–7 → reddedildi; ilerleme tablosu
11	24 Ağu Pzt	MCP entegrasyonu ve çok dil desteği	codeqa serve (3 araç); 8 dil; 2. haftanın commit'leri
12	25 Ağu Sal	Akış seti, kapsam metriği, çeşitlilik, ARA RAPOR	20 akış sorusu; kapsam metriği; sert kota reddi; ara rapor teslimi
13	26 Ağu Çar	Zor set ve üç genişletme eksen	2.025 kayıp docstring bulundu; kapsam 0.64 → 0.94; cevap %75 → %100
14	27 Ağu Per	Zor set bölmesi, iki red, performans, DEMO.md	Test bölmesi ilk temiz ölçüm; ask 68 sn → 6 sn; demo akışı
15	28 Ağu Cum	Paketleme, güven aralıkları, ikinci kod tabanı (Go)	pip install -e; Wilson GA; Prometheus + 24 soru
16	31 Ağu Pzt	Go ölçümü ve 'yalnızca Python' kararı	Sayılar taşınmadı; 7 dilde doküman hatası; çok dil kaldırıldı
17	1 Eyl Sal	Web arayüzü, proje kaydı, ilk demo provası	codeqa ui; dil işareti; duman testi; .mcp.json; iki demo düzeltilmesi
18	2 Eyl Çar	Saleor, büyütülmüş test bölmeleri, ayar taraması	238 soru; sayılar düştü; reranking 4. kez reddedildi
19	3 Eyl Per	Prova 2, referans hatası, arayüz, netleştirme, cevap ölçümü	Satır numaralı bağlam; DEMO_KOMUTLAR; facets; 26 soruluk cevap ölçümü
20	4 Eyl Cum	Sunum	Tanıtım sayfası, devir belgesi, 7 bölümlük canlı demo (~16 dk)

3. Gün gün çalışma

Hafta 1 — Temel katmanlar (10–14 Ağustos)

Gün 1 — Kurulum, problem tanımı ve indeksleme katmanı

10 Ağustos 2026, Pazartesi

- Problem tanımı: yeni bir projeye giren geliştirici ilk haftayı kodu anlamakla geçiriyor; 'ödeme nerede tahsil ediliyor', 'istek kaç kez yeniden deniyor' gibi soruları kıdemliye sormak zorunda kalıyor. Hedef: bu sorulara **kaynak gösteren** cevap.
- Mimari karar: kod sabit uzunlukta metin bloklarına değil, sözdizimi ağacı (AST) üzerinden bölünecek. Parçalar anlamlı bir bütün olarak kalıyor ve her parçanın gerçek satır aralığı biliniyor — dosya:satır referansı ancak böyle verilebiliyor.
- Ortam kurulumu (venv, pytest, ruff). `indexer.py`: fonksiyon / metot / sınıf / modül parçaları; imza, docstring, dekoratör ve satır aralığıyla. `docs.py`: markdown başlık hiyerarşisine göre bölme (kod bloğu içindeki başlık benzeri satırlar bölme noktası sayılmıyor). `models.py`: Chunk modeli, `embed_text` (bağlam etiketi + içerik), `content_hash`.
- CLI: `index / grep / stats`. 21 birim testi.
Çıktı: anthropic Python SDK üzerinde denendi: 1.097 dosya, 4.310 parça, 0 hata; rastgele 500 parçanın satır aralığı kaynak dosyalarla doğrulandı.

Gün 2 — Embedding katmanı

11 Ağustos 2026, Salı

- `embeddings.py`: Embedder arayüzü ve üç sağlayıcı — Voyage (`voyage-code-3`, bulut), Ollama (yerel; ek bağımlılık olmadan standart kütüphaneyle HTTP), hash (anahtarsız yer tutucu — anlamsal arama yapmaz, boru hattını denemek için).
- Vektör önbelleği: parçalar içerik karmasına göre `data/embeddings/` altında saklanıyor; değişmemiş parça yeniden embed edilmiyor, aynı içerikli parçalar tek kez hesaplanıyor. API maliyetini düşük tutmanın ana yolu.
- Kod tokenizer'ı: `getUserOrders` → `get, user, orders`. Bu olmadan 'sipariş id' araması `order_id`'yi bulamıyor.
- Tasarım kararı: sağlayıcı baştan takılabilir. İndekslemede kod tabanının tamamı sağlayıcıya gidiyor; müşteri kodunun dışarı çıkmadığı projelerde yerel model zorunluluk olabilir.
Çıktı: Üç sağlayıcı, disk önbelleği, tokenizer; `embed` komutu.

Gün 3 — Arama katmanı ve ilk ölçüm koşulları

12 Ağustos 2026, Çarşamba

- `search.py`: BM25 (tam isim eşleşmesi) + vektör araması (dolaylı anlatım), Reciprocal Rank Fusion ile birleştirme. Skorlar değil sıralamalar toplandığı için iki yöntemin ölçekleri normalize edilmek zorunda kalmıyor.
- CLI `search` komutu (`--provider, --mode`); 22 yeni test — ağ erişimi ve API anahtarı olmadan çalışıyor.
- İlk ölçüm koşulları kaydedildi: baseline hash, bm25 / hybrid / vector, voyage ile bm25 / hybrid / vector ve ilk örnek cevap (`runs/20260812-*`).
- Uçtan uca doğrulama: kendi projesi (150 parça) ve anthropic SDK (4.310 parça). İkinci koşuda 0 yeni embed — önbellek çalışıyor.
Çıktı: Hibrit arama çalışır durumda; 8 koşu kaydı.

Gün 4 — Cevaplama katmanı

13 Ağustos 2026, Perşembe

- `answer.py`: arama sonuçları bağlam olarak Claude'a veriliyor; model eksik kalan yerleri iki araçla kendisi okuyor — `read_file` ve `search_symbol`.
- Güvenlik: `read_file`'a gelen yol modelden geliyor, yani güvenilmez girdi. Repo köküne hapsedildi; `../..` ile dışarı çıkma denemesi reddediliyor ve bu davranış testlerle sabitlendi.
- Referans doğrulama: cevaptaki her `dosya:satır` için dosya var mı, satır dosya sınırları içinde mi kontrol ediliyor. Kısaltılmış yollar indekste tek eşleşme varsa kabul ediliyor.
- Prompt önbellegi açıldı: araç turları boyunca bağlam yeniden faturalanmıyor. Ölçülen fark: 42.000 taze girdi token'ı yerine 8 taze + 18.500 önbellegten.

Çıktı: `ask` komutu: referanslı cevap, doğrulanmış referans listesi, token ve maliyet dökümü.

Gün 5 — Ölçüm düzeneği

14 Ağustos 2026, Cuma

- `evaluation.py` ve `eval/questions.json`: aracın kendi kodu üzerinde 20 soru; her sorunun cevabının hangi dosyada olduğu elle işaretlendi.
- İki şey ayrı ölçülüyor: **getirme** (arama doğru parçayı ilk k'ya soktu mu — ücretsiz) ve **cevap** (model doğru dosyaya referans verdi mi — ücretli). Getirme bozuksa cevap da bozulur ama tersi doğru değil; ayrı ölçülmezse hangisinin düzeltileceği belli olmuyor.
- Koşullar `runs/` altına JSON olarak yazılıyor; aynı ölçüm için tekrar API çağırısı yok.
- İlk sonuç (20 soru, 249 parça): hash + hibrit recall %85 / MRR 0.403 → voyage-code-3 + hibrit recall %100 / MRR 0.750.

Çıktı: Ölçüm düzeneği; haftanın sonunda 108 test.

Hafta 2 — Ölçüm ve iyileştirme (17–21 Ağustos)

Gün 6 — Reranking, yerel modeller ve aracın bulduğu ilk gerçek hata

17 Ağustos 2026, Pazartesi

- `rerank.py`: Voyage rerank-2.5 ile ilk 20 adayın yeniden sıralanması (varsayılan kapalı). RRF'ye ağırlık ve havuz boyutu parametreleri.
- Yerel model desteği: Nomic ailesi için zorunlu görev örnekleri (`search_document` / `search_query`); öneksiz recall %40'tı. Ölçüm: bge-m3 %100 / 0.654, nomic-embed-text %65 / 0.302. Ders: kaybettiren yerel olmak değil, zayıf model — müşteri kodunun dışarı çıkamadığı projelerde araç kullanılabilir.
- Voyage hız limiti için yeniden deneme; önbelleg her yığından sonra diske yazılıyor, dakikalarca süren koşu ortada patlarsa iş kaybolmuyor.
- **Araç kendi hatasını buldu:** araca kendi koduyla ilgili bir soru sorulduğunda `content_hash`'in yalnızca `text`'ten hesaplandığı, oysa `embedding`'e giden metnin `context` + `text` olduğu görüldü. Sonuç: dosya taşınırken önbellegten eski vektör dönüyordu; anthropic SDK'sında 4.310 parça 3.549 vektöre çöküyordu. Doğrulandı ve düzeltildi.

Çıktı: Reranking ve yerel model seçenekleri; düzeltilmiş önbelleg anahtarı. Bu hata demonun 4. bölümü oldu.

Gün 7 — Büyük repo soru seti ve dev/test ayrımı

18 Ağustos 2026, Salı

- Küçük set (249 parça, 20 soru) yanıltıcı çıktı; gerçek boyutta ölçüm için anthropic SDK'sı üzerinde 60 soruluk set hazırlandı (`questions_anthropic.json`, 40 dev / 20 test). Her sorunun cevabı kod içinde grep ile aranarak etiketlendi.
- `Question.split` ve `load_questions(split=...)`. **Kural 1:** ayarlar yalnızca dev bölmesinde denener, rapor edilen sayı test bölmesinden alınır. Aynı set üzerinde hem ayar yapıp hem rapor etmek, ayarı o setin gürültüsüne uydurmak demek.

Çıktı: 60 soruluk büyük repo seti; dev/test altyapısı.

Gün 8 — Dil farkı bulgusu: hibrit arama bedava kazanç değil

19 Ağustos 2026, Çarşamba

- Hata: tokenizer Türkçe harfleri ayraç sayıyordu ('aşımı' → 'a' + 'm'); Türkçe yorumlu kod ve Türkçe sorgularda BM25 sessizce bozuluyordu. Regex Unicode-farkında yapıldı.
- Test bölmesi ölçümü (hiç ayar yapılmamış 20 soru): saf vektör %85 / 0.742, hibrit %80 / 0.581, BM25 %15 / 0.025. Küçük repoda tam tersiydi.
- Sebep dil: sorular Türkçe, anthropic SDK'sı İngilizce; sorgu kelimeleri kodda geçmediği için BM25'in tutunacağı şey kalmıyor, RRF zayıf sıralayıcıyı hesaba kattığı için hibrit aşağı çekiyor. Sorguyu İngilizceye çevirmek BM25'i kısmen kurtarıyor (%15 → %57) ama hibrit yine saf vektörü geçemiyor.
- Çıkarım: doğru arama modu repoya göre değişiyor, sabitlenmemeli. Ölçüm katmanı bu yüzden aracın yan ürünü değil parçası.

Çıktı: Unicode tokenizer; 'mod repoya göre seçilmeli' bulgusu (README Öğrenilenler §1).

Gün 9 — Contextual retrieval uygulaması

20 Ağustos 2026, Perşembe

- `contextual.py`: her parça için Haiku'ya 'bu parça dosyanın bütününde ne işe yarıyor' diye Türkçe tek cümle yazdırılıp embedding'e katılıyor.
- Maliyet kontrolü: dosya içeriği prompt önbellege alınıyor (önbelleksiz maliyet dosya boyutu × parça sayısı olurdu); üretilen cümleler diskte saklanıyor. Dosyalar paralel, aynı dosyanın parçaları sıralı — prompt öneki ancak öyle sabit kalıyor.
- Dayanıklılık: geçici hatalarda (zaman aşımı, hız limiti, 5xx) artan sürelerle yeniden deneme; kalıcı hatalarda (kredi bitti, anahtar geçersiz) temiz durma. İlk koşu 1.000 dosyada kredi bitince traceback atarak düşmüştü; kayıt aralığı 100'e çıkınca bir çöküşte 723 cümle kaybolmuştu → 20 dosyada bir diske yazma.
- `content_hash` bağlam değişince yeniden hesaplanıyor; aksi hâlde ön bellek eski vektörü döndürür ve bütün iş sessizce boşa gider.

Çıktı: `contextualize` komutu; anthropic SDK'sı için bağlamalı indeks üretildi.

Gün 10 — Contextual retrieval ölçümü ve karar; ilerleme tablosu

21 Ağustos 2026, Cuma

- Ölçüm (60 soru): vektör recall %85 → %87, MRR 0.690 → 0.714; BM25 recall %15 → %47. BM25 için büyük, vektör için kayda değmez kazanç; ~\$5–7 ve saatlerce koşu, +0.024 MRR için. **Reddedildi** (ilk reddedilen fikir). Muhtemel sebep: parçalar AST ile bölündüğü ve zaten bağlam etiketi taşıdığı için taban güçlüydü.
- İki küçük iyileştirme ölçüldü: modül seviyesi sabitler indekslendi (%87 → %88), soru etiketleri düzeltildi (%93 — bir **ölçüm düzeltmesi**, sistem kazancı değil: çok dosyalı sorulara tek dosya yazılmıştı).
- README'de ilerleme tablosu ve 'Öğrenilenler' bölümü açıldı.

Çıktı: Contextual retrieval: uygulandı, ölçüldü, kapatıldı. Haftanın işi 24 Ağustos'ta üç commit hâlinde depoya girdi.

Hafta 3 — Entegrasyon, akış ve zor sorular, ara rapor (24–28 Ağustos)

Gün 11 — Claude Code / MCP entegrasyonu ve çok dil desteği

24 Ağustos 2026, Pazartesi

- `codeqa serve`: MCP (Model Context Protocol) sunucusu, stdio üzerinden üç araç — `search_code`, `read_chunk`, `index_status`. Araç, geliştiricinin zaten kullandığı yerden (Claude Code) erişilebilir hâle geldi.
- Çok dil: tree-sitter ile sekiz dilde sembol çıkarma (Python, C, C++, Java, C#, Go, TypeScript, JavaScript). Doğruluk yalnızca Python'da ölçüldüğü için README'ye açık uyarı kondu. (Bu karar 16. günde ölçümle geri alındı.)
- Hafta 2'nin işi commit'lendi: cevaplama/ölçüm/reranking katmanları, büyük repo ölçümü ve dev/test ayrımı, contextual retrieval.

Çıktı: MCP sunucusu; 8 dil; 3 commit.

Gün 12 — Akış seti, kapsam metriği, çeşitlilik slotları — ve staj ara raporu

25 Ağustos 2026, Salı

- Kolay sette cevap doğruluğu tavana vurunca (%100) iyileştirmeler ölçülemez oldu. Projenin asıl vaadi akış takibi olduğu için cevabı 2–4 dosyaya yayılan 20 soruluk `questions_akis.json` yazıldı.
- Kapsam metriği:** çok dosyalı soruda recall yanıltıcı — üç dosyadan birini bulmak 'başarılı' saymaya yetiyor. Beklenen dosyaların yüzde kaçının getirildiği ayrı ölçülüyor.
- Çeşitlilik slotları: ilk 8 sonuçta ortalama yalnızca 3,1 farklı dosya vardı, 160 slotun 98'i tekrardı. Henüz temsil edilmemiş dosyaların en iyi parçası ilk k'nın arkasına ekleniyor → akış kapsamı %85 → %90, kolay %90 → %100, hiçbir metrik gerilemeden.
- Reddedilen: sert kota (dosya başına 1 parça). Kapsamı yükseltti ama sembol isabetini 0.778 → 0.444 düşürdü. **Kural 2** buradan çıktı: metrik müdahaleyi tanım gereği ödüllendiriyorsa kararı bağımsız bir ölçüt vermeli.
- Gerileme düzeltmesi: eşzamanlılık için eklenen kaydetme her sorguda 40 MB ön belleği baştan yazıyordu; toplu yazmaya çevrildi, ölçüm koşusu 10 dakikadan 45 saniyeye indi.
- Staj ara raporu teslim edildi** (4 sayfa: ulaşılanlar, sistem, ölçüm düzeneği, sonuçlar, öğrenilenler, sıradaki adımlar, açık konular).

Çıktı: Akış seti ve kapsam metriği; ara raporu; 187 test.

Gün 13 — Zor soru seti, indekslenmeyen dokümantasyon, üç genişletme eksen

26 Ağustos 2026, Çarşamba

- Akış seti de cevap tarafında tavana vurdu; birbirine çok benzeyen dosyalar arasından doğru varyantı seçtiren 12 soruluk `questions_zor.json` eklendi.
- İndeksleme hatası:** öznitelik docstring'leri (PEP 258 — atamadan sonra gelen çıplak string) hiç indekslenmiyordu. Kayıp: 1.097 dosyanın 624'ünde 2.025 docstring, 222.843 karakter. Ayrıca sınıf parçalarında alan listesi yoktu. İkisi düzeltildi; indeks metni %14 zenginleşti, akış MRR 0.777 → 0.810.
- Üç genişletme eksen, hiçbir eleme yapmıyor: **dosya çeşitliliği** (4 slot), **dizin kardeşi** (2 slot; arama doğru dizini bulup yanlış dosyayı getirdiğinde, iki isabet eşiğiyle), **import bağı** (2 slot; 'kimler kullanıyor' bir çağrı grafiği sorusu — bir soruda beklenen dosya sıralamada 136. sıradaydı; 5'ten çok kullanıcısı olan dosyalar atlanıyor).
- Tip ağırlıklandırması (metotsuz tip sınıfları 0.4) açıldı: tek başına zarar veriyor, genişletmelerle birlikte kazandırıyor (kolay kapsam 0.950 → 0.983).
- Getirme kapsamı: zor 0.639 → 0.944, akış 0.842 → 0.908, kolay 0.900 → 0.983. Kapsam slot eklendikçe düşmediği için karar cevap ölçümünden alındı: doğruluk %75 → %100, cevap dosya kapsamı %46 → %57, uydurma 0.
- Haiku ile `thinking` parametresi 400 döndürüyordu; düzeltildi. Ölçüm aleti olarak Haiku seçildi: iki Haiku koşusu \$0.55, tek Opus koşusu \$10.75, ve Opus tavana yakın çalıştığı için kolları ayırt edemiyordu.

Çıktı: Zor set; düzeltilmiş indeks; genişletme eksenleri; 205 test.

Gün 14 — Zor set bölmesi, iki reddedilen mekanizma, performans hatası, demo akışı

27 Ağustos 2026, Perşembe

- Zor set 12 → 26 soru ve bölündü: z01–z12 dev (genişletme eksenleri onların hatalarına bakılarak tasarlandığı için 'kirlili'), z13–z26 test. İlk kirlenmemiş ölçüm: getirme kapsamı %93, cevap doğruluğu %100, cevap dosya kapsamı %93, uydurma 0.
- Etiket gözden geçirmesi (z13, z23 fazla cömertti) — **Kural 3:** yalnızca kaçırılanlar değil setin tamamı geçirilir; düzeltme 'ölçüm düzeltmesi' diye işaretlenir.
- Dev'de kazanıp test'te sıfır veren iki mekanizma: re-export kabuklarını geri itmek (dev MRR 0.694 → 0.736, test 0.847 → 0.847) ve import bağının ileri yönü (dev kapsam 0.944 → 1.000, test 0.893 → 0.893). Prompt'a eklenen eksiksizlik kuralları da aynı sınavı geçemedi (akış setinde sıfır, referans sayısı %25 fazla). Üçü de geri alındı. Asıl bulgu: bölme olmasaydı üçü de rapora 'iyileştirme' diye girecekti.
- Performans: ask 68 saniye sürüyordu; profil, np.load'un .npz üzerinde tembel çalıştığını ve 48 MB dizinin döngüde 12.205 kez açıldığını gösterdi. Düzeltme sonrası 6,3 saniye. Test zamanlama değil arşivin kaç kez açıldığını sayıyor.
- DEMO.md ilk sürüm: yedi bölümlük akış, her adımda ne söyleneceği, komutlar; hepsi çalıştırılarak doğrulandı. MCP protokol düzeyinde elle doğrulandı (initialize → tools/list → tools/call). Kredi kontrolü eklendi. Refactor: referans genişletmesi iki fonksiyona bölündü; README 565 → 537 satır.

Çıktı: Test bölmesinden ilk temiz sayılar; demo senaryosu; 211 test.

Gün 15 — Paketleme, mod çözümü, güven aralıkları, ikinci kod tabanı (Go)

28 Ağustos 2026, Cuma

- Paketleme: pyproject.toml'a bağımlılıklar ve giriş noktası; pip install -e . ve codeqa komutu çalışıyor. requirements.txt ile eşitlik teste bağlandı.
- Mod çözümü: resolve_mode — hash yer tutucusunda hybrid, gerçek sağlayıcıda vector; açıkça verilen mod her zaman kazanıyor. README'deki uyarı yerine düzeltme.
- Güven aralıkları: ikili metrikler için Wilson skor aralığı, kapsam için standart hata. n=14'te %100 artık '%78–%100' diye görünüyor — sahte kesinlik kalktı.
- İkinci kod tabanı: Prometheus (Go, 453 kod dosyası, 15.197 parça) klonlandı; 24 soru dev/test ayrımı baştan kurularak yazıldı; CHANGELOG maddelerinden türetilmiş 6 soruluk bağımsız set.
eval/KULLANICI_DENEYI.md: değer hipotezini ('adapte olma süresini kısaltır') ölçmek için protokol.

Çıktı: Kurulabilir paket; güven aralıkları; Go seti hazır, embed koşusu başlatıldı. 216 test.

Hafta 4 — Genelleme, web arayüzü ve sunum (31 Ağustos – 4 Eylül)

Gün 16 — Go ölçümü, adil karşılaştırma ve 'yalnızca Python' kararı

31 Ağustos 2026, Pazartesi

- Go ölçüldü: kapsam %67 / MRR 0.406 (Python zor-test %93 / 0.847). Bir kod tabanında ölçülen başarımlar başkasını öngörmüyor.
- Sebepler aranırken gerçek bir kusur çıktı: Python'da docstring gövdenin içinde, diğer yedi dilde bildirimin üstünde ve parçaya hiç girmiyordu — incelenen 1.500 Go fonksiyonunun 607'sinde yorum vardı, kayıp %100. Düzeltildi; getirmeyi kıpırdatmadı ama doğruluk gereği tutuldu.
- Karşılaştırmanın adil olmadığı görüldü (**Kural 4**): anthropic SDK site-packages'tan kurulu olduğu için test/doküman içermiyor, Prometheus'un %51'i üretim dışı. Ablasyon: markdown parçaları indeksin %15'iyken sonuçların %28'ini kaplıyor; çıkarılınca MRR 0.406 → 0.586. Adil karşılaştırma: Python %93 / 0.847, Go %79 / 0.674 — fark yarıya indi ama kaybolmadı.
- Karar:** çok dil desteği kaldırıldı — ölçülmemiş yetenek savunulamayan iddia. Kod 3.813 → 3.530 satır, test 227 → 184, bağımlılık 16 → 8. Gerekece ve ölçüm README'de kaldı. Sıradaki adım: ikinci bir *Python* kod tabanı.
- Doğrulama koşusu: bütün setler yeniden ölçüldü, sayılar README ile birebir. Ama giriş cümlesi yanlış: 'uydurma referans hiç görülmedi' deniyordu; kayıtlarda bir gerçek uydurma vardı — model dizin adını Türkçeye çevirmişti (türler/beta/...). Doğrulama katmanı yakalamıştı. Cümle düzeltildi; örnek Cevaplama bölümüne yazıldı.

Çıktı: Yalnızca Python; README derlendi; 6 commit; 184 test.

Gün 17 — Web arayüzü, proje kaydı, MCP kaydı ve ilk demo provası

1 Eylül 2026, Salı

- codeqa ui: bağımlılıksız yerel web arayüzü (`http.server`, yalnızca 127.0.0.1). Projeler arayüzden ekleniyor, `data/projects.json`'da tutuluyor. Ekleme iki adımlı: **tara** (bedava; dosya sayısı, bileşim, maliyet tahmini) → **devam et** (embed, ilerleme çubuğu, önbellekten gelen parça sayısı).
- Referansı tek tıkla doğrulama: cevaptaki `dosya:satır`'a tıklayınca dosyanın o satırı vurgulu açılıyor. Dosya okuma cevaplama katmanı ile aynı yol hapsini kullanıyor (`resolve_in_repo`).
- İki ucuz kontrol, ikisi de 'ölçüm değil' etiketli: dil işareti (Türkçe metin oranına göre mod önerisi) ve duman testi (25 sembol). Duman testi ilk hâlde 17/25 veriyordu — kaçırılanlar bilerek geri itilen tip sınıflarıydı; örneklem `chunk_weight` ile süzülünce 23/25. `eval/SORU_SETI.md`: yeni repo için gerçek soru seti yazma rehberi.
- MCP: sunucu `.mcp.json` ile kayıtlı; `serve` artık `.env` ve önbelleği indeksin yanından çözüyor (istemci sunucuyu kendi dizininde başlatıyordu). `ask` çıktısındaki gizli önbellek token'ları gösterildi; gerçek maliyet 0,6–2,2 sent.
- İlk demo provası, iki düzeltme: (1) canlı soru dev bölmesindeki a02'ye çok benziyordu — senaryoya açıklama ve test bölmesinden ikinci soru (a17) eklendi; (2) Claude Code'da retry sorusu araç çağırılmadan ezberden cevaplandı — yerine ezberlenemeyecek bir iç detay (skill arşivi güvenliği, z13) konu; dört referansın dördü doğrulandı.

Çıktı: Web arayüzü; proje kaydı; 31 yeni test (215); demo senaryosu düzeltildi.

Gün 18 — İkinci Python kod tabanı (Saleor), büyütülmüş test bölmeleri, ayar taraması

2 Eylül 2026, Çarşamba

- Saleor (açık kaynak e-ticaret, Django) eklendi: elle yazılmış bir iş uygulaması — ürün, fiyat, sipariş, ödeme, stok, vergi; müşteri projelerine kütüphaneden çok daha yakın. Test ve migration dizinleri dışlanarak bileşim anthropic SDK ile eşitlendi (1.060 / 1.099 dosya, ikisi de %99+ üretim kodu). 12.076 parça, 40 soru.
- Test bölmeleri büyütüldü: soru sayısı 126 → 238, test 44 → 142. Üç sette de sayılar düştü (zor %100 → %96, MRR 0.847 → 0.757; akış %100 → %93; kolay %98 → %92). Araç değişmedi — eski sayılar küçük örneklem iyimserliğiymiş. Güven aralıkları daraldı (zor: 22 → 13 puan). Kendi repo setine ilk kez bölme konu.
- Yeni 92 soru LLM ile yazıldı; kurallara uyduruldu (sorular kod okunmadan, etiketler grep ile — codeqa ile değil). Zor sette insanın yazdığı 14 soru %100 / 0.847, LLM'in yazdığı 12 soru %92 / 0.653: insan gözden geçirmesi açık iş olarak yazıldı.
- Saleor bölmesi dengesizdi (çok dosyalı sorular dev %21 / test %50); sonuca bakmayan bir kuralla yeniden dağıtıldı (dev %43 / test %38) ve **ölçüm düzeltmesi** diye işaretlendi. Saleor test: recall %100, kapsam %96, MRR 0.573 — doğru dosyayı buluyor ama daha aşağıda sıralıyor; aracın zayıf noktasını gösteren en somut sayı.
- Ayar taraması (üç dev bölmesi, 8 kol: çeşitlilik / dizin / import slotları, havuz, hibrit, tip ağırlığı): hiçbirini kıpırdamadı; varsayılanlar iki kod tabanında da en iyisi. Reranking dev'de +0.10, test'te -0.09 → **dördüncü kez reddedildi**.
- Toparlama: JSONL okuma/yazma altı yerden bire indi; ölü kod yok; README manşet sayıları güncellendi ve düşüşün sebebi yazıldı; tarihsel tablolara dokunulmadı.

Çıktı: İki kod tabanı, beş set, 238 soru; README güncel; 217 test.

Gün 19 — İkinci demo provası, referans hatası, arayüz tasarımı, netleştirme, cevap ölçümü

3 Eylül 2026, Perşembe

- Demo provası: on komutun onu koşuldu; senaryo eski bölmelerin sayılarını taşıyordu — altı uyumsuzluk düzeltildi, ekranda artık görünen tek hata işareti (z34) için 'sakla değil göster' cümlesi yazıldı, Saleor'da canlı soru adımı eklendi (11,7 sn, ~1,3 sent). Prova sırasında kopyalanan kod bloğu tırnakları zsh'de iç içe kabuk açtı ve altı komut sessizce koşmadı → DEMO_KOMUTLAR.txt (DEMO.md'den üretiliyor, senkron teste bağlı).
- Referans hatası:** tanıtım sayfası için gerçek cevap örneği hazırlanırken beş referansın ikisi tutmadı (`_constants.py:3` bir import satırıydı). Sebep: bağlam parçaları modele satır numarasız gidiyordu, model parçanın yalnızca başlangıç satırını gösterebiliyordu. `_format_hit` artık satır numaralı veriyor; iki kod tabanında on referansın onu iddia edilen satıra oturdu.
- Arayüz tanıtım sayfasıyla aynı tasarım diline geçti (kâğıt zemin, doğrulanmış yeşil, uyarı kıızılı; başlık / metin / mono yazı tipleri, çevrimdışı düşüş). JS'e dokunulmadı. Dışlama alanı eklendi: kendi projesini tarayan biri `repos/` yüzünden 42.451 parça / ~\$1,60 görüyordu → 588 parça.
- Netleştirme (`facets.py`): 'ödeme' gibi belirsiz sorguda ilk sekiz baştan sona soyut arayüz katmanıydı; havuzun ilk 300 adayı dizin ağacına göre öbeklenip kullanıcıya menü olarak gösteriliyor. Ölçüldü (düz / menü / tavan), kazanç ilan edilmedi: dizin yapısı anlam taşıyan kod tabanlarında çalışıyor, üretilmiş sarmalayıcılarla dolu olanlarda değil. Aramayı dizine hapsetmek denendi ve reddedildi.
- Cevap ölçümü 26 soruluk güncel bölmede koşuldu: doğruluk %100 (26/26), dosya kapsamı %91, uydurma 0. Cevap kapsamı getirme kapsamını (%90) geçiyor: getirmenin kaçırıldığı tek soruda model iki `read_file` çağırısıyla dosyaya kendi gitti.

Çıktı: Prova temiz; satır numaralı bağlam; yeni arayüz; güncel cevap sayıları; 218 test.

Gün 20 — Sunum

4 Eylül 2026, Cuma

- **Tanıtım sayfası** (tek sayfa, tarayıcıda): giriş ve özet, boru hattı (parçalama → embedding → arama → cevaplama), modül listesi, referansları tek tek doğrulanmış gerçek bir cevap örneği, ölçüm tabloları, reddedilen fikirler defteri, 'Aracı çalıştır' düğmesiyle yerel arayüze geçiş. Sunum bu sayfa üzerinden yapıldı, ayrı slayt hazırlanmadı.
- **Devir belgesi** (DEVIR.md): proje nedir, güncel durum, yöntem kuralları, reddedilen yedi fikir, çalışan mekanizmalar, bulunan gerçek hatalar, sıradaki adımlar, pratik bilgiler. Belgedeki her sayı programla doğrulandı.
- Sunum öncesi hazırlık: indeksi ısıtma, hash fallback, kredi kontrolü, MCP bağlantısı; üç fallback yolu (voyage arama, hash + BM25, grep).
- **Canlı demo, 7 bölüm (~16 dakika)**: 1) problem — 2) canlı soru ve referansa tıklayarak doğrulama, test bölmesinden ikinci soru — 3) neden güvenilir: ölçüm düzeneği, dev/test, iki kod tabanı, hatanın saklanmaması — 4) aracın kendi kodunda bulduğu hata — 5) Claude Code içinden kullanım — 6) neyin işe yaramadığı: reddedilen fikirler — 7) açık sorular: kullanıcı deneyi, LLM sorularının gözden geçirilmesi, yerel model zorunlu mu.

Çıktı: Sunum tamamlandı; proje devredilebilir durumda.

4. Sunum akışı (Gün 20 ayrıntısı)

Bölüm	Süre	İçerik
1. Problem	1 dk	Yeni projeye adapte olma maliyeti; 'kaynak gösteren cevap' fikri
2. Canlı soru	4 dk	'İstek kaç kez yeniden deneniyor?' → referanslı cevap, referansa tıklayıp satırı görme; test bölmesinden ikinci soru
3. Neden güvenilir	4 dk	Getirme / cevap ayrımı, dev/test bölmesi, güven aralıkları, ikinci kod tabanı; ekrandaki hata işareti saklanmıyor
4. Aracın bulduğu hata	2 dk	content_hash hatası: 4.310 parça 3.549 vektöre çöküyordu
5. Claude Code entegrasyonu	2 dk	MCP sunucusu; ezberlenemeyecek iç detay sorusu, dört doğrulanmış referans
6. Neyin işe yaramadığı	2 dk	Yedi reddedilen fikir ve her birinin ölçümü — en güçlü bölüm
7. Açık sorular	1 dk	Kullanıcı deneyi, LLM sorularının insan gözünden geçmesi, yerel model kararı

Ek A — Denenip reddedilen fikirler

Her biri uygulandı, ölçüldü ve karar veriyeye dayandırıldı. Reddedilenlerin kodu ve ölçüm notu depoda duruyor; gerekçesiz yeniden denenmemeli.

Fikir	Gün	Ölçüm	Karar
Hibrit arama (varsayılan)	8	Büyük İngilizce repoda saf vektör %85 / 0.742, hibrit %80 / 0.581	Mod sağlayıcıya göre çözülüyor
Contextual retrieval	10	Vektör +2 puan, BM25 %15 → %47; ~\$5–7, saatler	Varsayılan kapalı
Sert kota (dosya başına 1 parça)	12	Kapsam ↑ ama sembol isabeti 0.778 → 0.444	Reddedildi
Prompt eksiksizlik kuralları	14	Zor +15 puan, akışta 0, referans %25 fazla	Geri alındı
Re-export kabuklarını geri itmek	14	Dev MRR 0.694 → 0.736, test 0.847 → 0.847	Varsayılan kapalı
Import bağının ileri yönü	14	Dev kapsam 0.944 → 1.000, test 0.893 → 0.893	Varsayılan kapalı
Çok dil desteği	16	Go kapsam %79 / 0.674 (Python %93 / 0.847), 6 dil hiç ölçülmedi	Kaldırıldı
Reranking (rerank-2.5)	18	Dev +0.10, test -0.09 (dördüncü deneme)	Varsayılan kapalı
Aramayı seçilen dizine hapsetmek	19	Dev tavan: zor %92 → %58, akış %80 → %70	Reddedildi

Ek B — Bulunan ve düzeltilen gerçek hatalar

Hata	Gün	Etkisi
content_hash yalnızca text'ten hesaplanıyordu	6	4.310 parça 3.549 vektöre çöküyordu; taşınan dosya eski vektör alıyordu (araç kendi buldu)
Tokenizer Türkçe harfleri ayraç sayıyordu	8	Türkçe kod tabanında BM25 sessizce bozuktı
Önbellek her sorguda baştan yazılıyordu	12	Ölçüm koşusu 10 dk → 45 sn
Öznitelik docstring'leri indekslenmiyordu (PEP 258)	13	2.025 docstring / 222.843 karakter kayıp; indeks metni %14 zenginleşti
np.load tembel dizi döngüde 12.205 kez açılıyordu	14	ask 68 sn → 6,3 sn
Bildirim üstü yorumlar 7 dilde parçaya girmiyordu	16	Go'da docstring taşıyan parça %0 → %36

Hata	Gün	Etkisi
Model dizin adını Türkçeye çevirdi (türler/beta/...)	16	Tek gerçek uydurma referans; doğrulama katmanı yakaladı
Duman testi bilerek geri itilen tip sınıflarını sayıyordu	17	17/25 → 23/25 (kasıtlı davranış arıza gibi görünüyordu)
ask, önbellek yazma token'larını gizliyordu	17	Maliyet iddiası ekranla çelişiyordu; gerçek 0,6–2,2 sent
Bağlam parçaları satır numarasız gidiyordu	19	Referanslar parçanın başını gösteriyordu (_constants.py:3 = import); 10/10 düzeldi
Markdown tırnakları zsh'de iç içe kabuk açıyor	19	Provada altı komut sessizce koşmadı → DEMO_KOMUTLAR.txt

Ek C — Yöntem kuralları

- Kural 1 — dev/test ayrımı.** Ayarlar yalnızca dev bölümünde denenir; rapor edilen sayı hiç dokunulmamış test bölümünden alınır.
- Kural 2 — metrik müdahaleyi ödüllendiriyor mu?** Kapsam slot eklendikçe düşemez; kararı bağımsız bir ölçüt (cevap ölçümü, referans/cevap sayısı) vermeli.
- Kural 3 — setin tamamı gözden geçirilir.** Yalnızca kaçırılan soruların etiketini sorgulamak tek yönlü düzeltmedir; düzeltmeler 'ölçüm düzeltmesi' diye işaretlenir, sistem kazancı diye sunulmaz.
- Kural 4 — indeks bileşimi eşitlenir.** İki kod tabanı karşılaştırılırken test/doküman/üretilmiş kod oranları eşitlenmeden fark yorumlanmaz.

Ek D — Sunum sonrası açık işler

- Kullanıcı deneyi: 'adapte olma süresini kısaltır' iddiası ölçülmedi; protokol hazır (eval/KULLANICI_DENEYI.md), iki kişi, yarım gün.
- LLM ile yazılan 92 sorunun insan gözünden geçmesi (setin tamamı, Kural 3).
- Saleor ve akış setlerinde cevap tarafı ölçümü; cevaplama katmanı ikinci kod tabanında henüz sınanmadı.
- Organizasyon seviyesindeki API anahtarları için anthropic-workspace-id başlığı desteği (12 Eylül, depoya henüz girmedir).
- Otomatik soru üretimi: yeni repo eklendiğinde soru setini aracın üretmesi — elle yazılmış setlerle aynı sonucu verip vermediği ölçülerek karar verilecek.

Ek E — Depo geçmişi (commit tarihleri)

Tarih	Commit	Konu
10 Ağu	2	İndeksleme katmanı; embedding ve hibrit arama katmanı
24 Ağu	3	Cevaplama / ölçüm / reranking; büyük repo ve dev/test; kontekstual retrieval
26 Ağu	2	MCP, çok dil, çeşitlilik slotları; zor set ve üç genişletme ekseni
27 Ağu	4	Zor set bölmesi ve iki red; O(n) önbellek hatası ve DEMO.md; MCP doğrulama; toparlama
31 Ağu	6	Paketleme ve Go; Go ölçümü; adil karşılaştırma; çok dil kaldırıldı; temizlik; doğrulama koşusu
1 Eyl	9	Web arayüzü; demo provası; Saleor ve büyütülmüş bölmeler; bölme düzeltmesi; toparlama; prova düzeltmeleri; DEMO_KOMUTLAR; satır numaralı bağlam; arayüz tasarımı
2 Eyl	3	Devir belgesi; netleştirme öbekleri; 26 soruluk cevap ölçümü